

第6 部分

机器学习

参考书籍

- **机器学习（西瓜书）**，周志华
- **统计学习方法**，李航
- **神经网络与深度学习**，邱锡鹏

参考在线视频

- https://www.bilibili.com/video/BV164411b7dx/?spm_id_from=333.337.search-card.all.click&vd_source=2bb9341643c0473c9f59aa709158a7a7
吴恩达
- <https://www.bilibili.com/video/av12463015?from=search&seid=13685429168514529083> **林轩田**
- <https://www.bilibili.com/video/av36760800?from=search&seid=18057323753895497591> **林轩田**

什么是机器学习

- 如果一个智能体通过对世界进行观测来提高它的性能，我们称其为**智能体学习**（Agent learning）。
 - 学习可以是简单的，例如记录一个购物清单
 - 学习也可以是复杂的，例如爱因斯坦推断关于宇宙的新理论
- 当智能体是一台计算机时，我们称之为**机器学习**（machine learning）：
- 一台计算机观测到一些数据，基于这些数据构建**一个模型**，并将这个模型作为关于世界的一个假设以及用于求解问题的软件的一部分

机器学习 $\approx$ 构建一个映射函数

▶ 语音识别

 $f($

 $) = \text{“你好”}$

一个模型


▶ 图像识别

 $f($

9

 $) = \text{“9”}$

▶ 围棋

 $f($

 $) = \text{“6-5”}$ (落子位置)


▶ 机器翻译

 $f($

“你好!”


 $) = \text{“Hello!”}$

什么是机器学习?



机器学习的定义

- **机器学习：**从数据中获得决策（预测）函数使得机器可以根据数据进行自动学习，通过算法使得机器从大量历史数据中学习规律从而对新的样本做决策。



机器学习的学什么？ 学习如何改进各个组件


- **智能体7大组件：**
- (1) 从当前状态条件到动作的直接映射；
- (2) 用于从感知序列推断世界相关性质的方法；
- (3) 关于世界演化方式的信息，以及关于智能体可以采取的可能动作所导致的结果的信息；
- (4) 表示状态意向的效用信息；
- (5) 表示动作意向的动作-价值信息；
- (6) 最希望达到的状态，即目标；
- (7) 问题生成器、评判标准和使系统得以改进的学习元素。

机器学习的


- 为什么我们希望一台机器进行学习？为什么不通过合适的方式编程然后让它运行呢？
- 其一，程序的设计者无法预见未来所有可能发生的情形。
- 其二，有时候设计者并不知道如何设计一个程序来求解目标问题。

常见的机器学习问题（输出的角度）


- **分类 (Classification)** : 当输出是一个有限集合中的某个值时
- **回归 (Regression)** : 当输出是一个数值时
- **聚类 (Clustering)**



分类



回归




聚类

常见的机器学习类型 (从输入的角度)


监督学习(supervised learning)
数据有标签、一般为回归或分类等任务

无监督学习(un-supervised learning)
数据无标签、一般为聚类或降维任务

强化学习(reinforcement learning)
序列数据决策学习，一般为与环境交互中学习



半监督学习
(semi-supervised learning)



6.1 监督学习—定义

给定一个**训练集** (training set) 含有 N 个“输入-输出”对样例:

$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$$


其中每一对数据都由一个未知的函数 $y = f(x)$ 生成,

目标: 如果输出是离散点对, 希望寻找一个**一致性假设** h (consistent hypothesis) 使得对训练集中的任意一个 x_i , 都有 $h(x_i) = y_i$ 。
如果输出是连续值, 则希望寻找一个**最佳拟合函数** (best-fit function) , 使得每一个 $h(x_i)$ 与 y_i 非常接近。

6.1 监督学习—评估标准


评估： 用一个**测试集** (test set) ——第二组样本数据对 (x_i, y_i) ——来评估假设。
如果 h 准确地预测了测试集的输出，则称 h 具有很好的**泛化**(generalize)能力。

偏差与方差



偏差与方差

■ 当我们的模型表现不佳时，通常是出现两种问题，一种是**高偏差**问题，另一种是**高方差**问题，识别它们有助于选择正确的优化方式。



偏差度量了学习算法期望预测与真实结果的偏离程度；**刻画了学习算法本身的拟合能力。**

方差度量了同样大小训练集的变动所导致的学习性能的变化；**刻画了数据扰动所造成的影响。**

像打靶一样，偏差描述了射击总体是否偏离了我们的目标，而方差描述了射击准不准。

偏差—方差权衡

- **偏差产生原因**：模型过于简单，或者模型的假设空间对数据的表达能力不足，导致无法捕捉数据中的真实模式，出现**欠拟合**（Underfitting）现象。
- **方差产生原因**：模型过于复杂，对训练数据中的噪声和细微变化都过度敏感，导致模型在不同训练集上学习到不同的模式，从而在新数据上表现不稳定，出现过拟合（Overfitting）现象。

奥卡姆剃刀原则：他的原则“如无必要，勿增实体”

倾向于选择简单假设空间的第二个原因是，我们可能会在学习完 h 后使用它，当 h 是一个线性函数时，计算 $h(x)$ 是很快的，

高偏差与高方差的改进策略

■ 高方差:

- ◆ 采集更多的样本数据
- ◆ 减少特征数量，去除非主要的特征
- ◆ 增加正则化参数 λ

■ 高偏差:

- ◆ 引入更多的相关特征
- ◆ 采用多项式特征
- ◆ 减小正则化参数 λ

餐厅等待问题

输入x是有 10个属性值的向量，每个属性都是离散的值。


- (1) 候补(Alternate):附近是否存在其他合适的可以代替的餐厅。
- (2) 吧台 (Bar) : 该餐厅是否有舒适的吧台用于等待。
- (3) 周五/六 (Fri/Sat) : 今天是否为周五或周六。
- (4) 饥饿 (Hungry) : 现在是不是饿了。
- (5) 顾客 (Patrons) : 目前餐厅有多少顾客 (值为None、Some、Full) 。
- (6) 价格 (Price) : 餐厅的价格范围 (\$、\$\$、\$\$\$) 。
- (7) 下雨 (Raining) : 外面是否正在下雨
- (8) 预约 (Reservation) : 我们是否有预订。
- (9) 种类 (Type) : 餐厅种类 (French、Italian、Thai或 Burger) 。
- (10) 预计等待 (WaitEstimate) : 对等待时间的估计 (0 ~ 10分钟、10 ~ 30分钟、30 ~ 60分钟或 60分钟)

输出y是一个布尔变量，即是否等待 (WillWait)

餐厅等待问题领域的样例

样例	输入属性										输出
	<i>Alternate</i>	<i>Bar</i>	<i>Fri/Sat</i>	<i>Hungry</i>	<i>Patrons</i>	<i>Price</i>	<i>Raining</i>	<i>Reservation</i>	<i>Type</i>	<i>WaitEstimate</i>	<i>WillWait</i>
x_1	Yes	No	No	Yes	Some	\$\$\$	No	Yes	French	0 ~ 10	$y_1 = \text{Yes}$
x_2	Yes	No	No	Yes	Full	\$	No	No	Thai	30 ~ 60	$y_2 = \text{No}$
x_3	No	Yes	No	No	Some	\$	No	No	Burger	0 ~ 10	$y_3 = \text{Yes}$
x_4	Yes	No	Yes	Yes	Full	\$	Yes	No	Thai	10 ~ 30	$y_4 = \text{Yes}$
x_5	Yes	No	Yes	No	Full	\$\$\$	No	Yes	French	> 60	$y_5 = \text{No}$
x_6	No	Yes	No	Yes	Some	\$\$	Yes	Yes	Italian	0 ~ 10	$y_6 = \text{Yes}$
x_7	No	Yes	No	No	None	\$	Yes	No	Burger	0 ~ 10	$y_7 = \text{No}$
x_8	No	No	No	Yes	Some	\$\$	Yes	Yes	Thai	0 ~ 10	$y_8 = \text{Yes}$
x_9	No	Yes	Yes	No	Full	\$	Yes	No	Burger	> 60	$y_9 = \text{No}$
x_{10}	Yes	Yes	Yes	Yes	Full	\$\$\$	No	Yes	Italian	10 ~ 30	$y_{10} = \text{No}$
x_{11}	No	No	No	No	None	\$	No	No	Thai	0 ~ 10	$y_{11} = \text{No}$
x_{12}	Yes	Yes	Yes	Yes	Full	\$	No	No	Burger	30 ~ 60	$y_{12} = \text{Yes}$

6.2 决策树学习



决定是否在餐厅等待的决策树

决策树 (decision tree) 表示了这么一类函数——它将属性值向量映射到单个输出值（即“决策”）。

决策树通过执行一系列测试来实现其决策，它从根节点出发，沿着适当的分支，直到到达叶节点为止。树中的每个内部节点对应于一个输入属性的测试，该节点的分支用该属性的所有可能值进行标记，叶节点指定了函数要返回的值。

1.决策树的表达能力

- 一棵布尔型的决策树等价于如下形式的逻辑语句：

$$Output \Leftrightarrow (Path_1 \vee Path_2 \vee \cdots)$$

$Path_i$: 从根节点到true叶节点的路径上的属性-值测试形式

$$A_m = v_x \wedge A_n = v_y \wedge \cdots$$

这意味着命题逻辑中的任何函数都可以表示为决策树。

注意：（1）但有些函数并不能被简洁地表示，例如投票函数，当且仅当超过一半的输入为真时，它的输出为真，它需要指数量级大小的决策树来表示；
（2）属性值数量太大也不能用决策树有效表示。

2.从样例中学习决策树


- **问题：**如何找到一棵与样例保持一致并尽可能小的决策树？

算法思路：贪心与分治的策略


总是**首先测试当前最重要的属性**，然后**递归地**去解决由该测试结果可能产生的更小的子问题。

◆ **“最重要的属性”**指的是对一个样例的分类结果能产生最大影响的属性

2.从样例中学习决策树



(a)



(b)

2.从样例中学习决策树

对于这些递归子问题，我们需要考虑以下4个方面。


(1) 剩余的样例全为正（或全为负），达成目标，可以输出Yes或No。

(2) 如果既有正样例又有负样例，那么需要继续选择最好的属性对样例进行分割。

(3) 分割后没有剩余的样例，则表示没有观测到该属性值组合的样例，将返回构造该节点的父节点的样例集中最常见的输出值。

(4) 分割后没有任何其他的属性剩余，但是存在正负两种样例，这意味着，这些样例有完全相同的属性值组合，但分类不同。

这是可能发生的，或是因为数据中存在错误或噪声（noise），或是因为该领域是非确定性的，再或是因为我们无法观测到可以区分样例的属性。此时的最好的选择就是返回剩余样例中最常见的输出值。



决策树学习基本算法

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;

属性集 $A = \{a_1, a_2, \dots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

1: 生成结点 node;

2: if D 中样本全属于同一类别 C then

3: 将 node 标记为 C 类叶结点; return

4: end if

5: if $A = \emptyset$ OR D 中样本在 A 上取值相同 then

6: 将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return

7: end if

8: 从 A 中选择最优划分属性 a_* ;

9: for a_* 的每一个值 a_*^v do

10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;

11: if D_v 为空 then

12: 将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return

13: else

14: 以 TreeGenerate($D_v, A \setminus \{a_*\}$) 为分支结点

15: end if

16: end for

输出: 以 node 为根结点的一棵决策树

递归返回, 情形(1).

递归返回, 情形(2).

我们将在下一节讨论如何获得最优划分属性.

递归返回, 情形(3).


从 A 中去掉 a_* .

(1) 当前结点包含的样本全部属于同一类别, 无需划分

(2) 当前属性集为空, 或所有样本在所有属性上取值相同, 无法划分

(3) 当前结点包含的样本集合为空, 不能划分

决策树学习算法示例




- 注意，样例集是算法的一个输入，但是样例不出现在算法所返回的任何树中。
- 一棵树由内部节点上的属性的测试、分支上的属性值和叶节点上的输出组成。
- 算法着眼于 examples，而不是正确的函数，从现实来看，它的假设（见图19-6）不仅与所有样例一致，而且比原始的树简单得多！
- 对于稍有不同的输入样例，树的形状可能会非常不同，但它所表示的函数是相似的。

学习曲线

- 学习曲线（learning curve）可用来评估学习算法的表现。

在这个图中，有100个样例可供学习使用，我们将它们随机分割为一个训练集和一个测试集。我们使用训练集学习假设 h ，并用测试集来度量其准确率。我们可以从大小为1个样例的训练集开始训练与测试的过程，每次增加1个训练样例，直到训练集包含99个样例。对于每种大小的训练集，我们实际操作时重复随机分割训练集和测试集的过程20次，并对这20次试验的结果取平均值。曲线的结果表明，随着训练集大小的增加，准确率将提高。出于这个原因，学习曲线也被称为快乐图（happy graph）。在这张图中，准确率最终达到了95%，并且从趋势上看，如果有更多的数据，曲线可能会继续上升。



一个决策树的学习曲线，数据集为从餐厅等待问题领域中随机产生的100个样例。图中每个点都是20次试验的均值

3.选择测试属性

- 决策树学习的关键在于**如何选择最优划分属性**。一般而言，随着划分过程不断进行，我们希望决策树的分支结点所包含的样本**尽可能属于同一类别**，即结点的“纯度”(purity)越来越高
- 经典的属性划分方法：
 - 信息增益 (ID3)
 - 信息增益率 (C4.5)

信息增益

- “**信息熵**”是度量样本集合纯度最常用的一种指标，假定当前样本集D中第k类样本所占的比例为 $p_k = (K = 1, 2, \dots |Y|)$, 则D的信息熵定义为

$$Ent(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k$$

$Ent(D)$ 的值越小，则D的纯度越高

- 计算信息熵时约定：若 $p=0$, 则 $p \log_2 p = 0$
- $Ent(D)$ 的最小值为0，最大值为 $\log_2 |Y|$

例如：1枚公平硬币被抛掷的熵确实是1位
一个四面均匀的骰子的熵是2位

离散属性 a 有 V 个可能的取值 $\{a^1, a^2 \dots a^V\}$, 用 a 来进行划分, 则会产生 V 个分支结点, 其中第 v 个分支结点包含了 D 中所有在属性 a 上取值为 a^v 的样本, 记为 D^v 。则可计算出用属性 a 对样本集 D 进行划分所获得的“信息增益”:



$$Gain(D, a) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v)$$

为分支结点权重, 样本数越多的分支结点的影响越大

一般而言, **信息增益越大**, 则意味着使用属性 a 来进行划分所获得的“**纯度提升**”越大

ID3决策树学习算法[Quinlan, 1986]以信息增益为准则来选择划分属性

信息增益示例1



$$Ent(D) = - \sum_{k=1}^{|Y|} p_k \log_2 p_k = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$$

$$Gain(D, type) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v) = 1 - \left(\frac{2}{12} (-(0.5 \log_2 0.5 + 0.5 \log_2 0.5)) + \left(\frac{2}{12} * 1 + \frac{4}{12} * 1 + \frac{4}{12} * 1 \right) \right) = 0$$

$$Gain(D, patrons) = Ent(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Ent(D^v) = 1 - \left(\frac{2}{12} (-(1 \log_2 1 + 0 \log_2 0)) + \frac{4}{12} (-(1 \log_2 1 + 0 \log_2 0)) + \frac{6}{12} \left(- \left(\frac{2}{6} \log_2 \frac{2}{6} + \frac{4}{6} \log_2 \frac{4}{6} \right) \right) \right) = 1 - 0.5 * 0.9183 = 0.541$$

信息增益实例2

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

该数据集包含17个
训练样本 $|\mathcal{Y}| = 2$,
其中正例占 $p_1 = \frac{8}{17}$,
反例占 $p_2 = \frac{9}{17}$, 计
算得到根结点的信
息熵为

$$\text{Ent}(D) = - \sum_{k=1}^2 p_k \log_2 p_k = -(\frac{8}{17} \log_2 \frac{8}{17} + \frac{9}{17} \log_2 \frac{9}{17}) = 0.998$$

□ 以属性“色泽”为例，其对应的3个数据子集分别为 D^1 (色泽=青绿)， D^2 (色泽=乌黑)， D^3 (色泽=浅白)

□ 子集 D^1 包含编号为{1, 4, 6, 10, 13, 17}的6个样例，其中正例占 $p_1 = \frac{3}{6}$ ，反例占 $p_2 = \frac{3}{6}$ ， D^2 、 D^3 同理，3个结点的信息熵为：

$$\text{Ent}(D^1) = -(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}) = 1.000$$

$$\text{Ent}(D^2) = -(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}) = 0.918$$

$$\text{Ent}(D^3) = -(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}) = 0.722$$

□ 属性“色泽”的信息增益为

$$\begin{aligned} \text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - (\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722) \\ &= 0.109 \end{aligned}$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

□ 类似的，其他属性的信息增益为

$$\text{Gain}(D, \text{根蒂}) = 0.143$$


$$\text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{纹理}) = 0.381$$

$$\text{Gain}(D, \text{脐部}) = 0.289$$

$$\text{Gain}(D, \text{触感}) = 0.006$$

□ 显然，属性“纹理”的信息增益最大，其被选为划分属性



编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否



图 4.3 基于“纹理”属性对根结点划分

“纹理”不再作为候选划分属性。

然后, 决策树学习算法将对每个分支结点做进一步划分. 以图 4.3 中第一个分支结点(“纹理=清晰”)为例, 该结点包含的样例集合 D^1 中有编号为 {1, 2, 3, 4, 5, 6, 8, 10, 15} 的 9 个样例, 可用属性集合为 {色泽, 根蒂, 敲声, 脐部, 触感}. 基于 D^1 计算出各属性的信息增益:


$$\text{Gain}(D^1, \text{色泽}) = 0.043; \quad \text{Gain}(D^1, \text{根蒂}) = 0.458;$$

$$\text{Gain}(D^1, \text{敲声}) = 0.331; \quad \text{Gain}(D^1, \text{脐部}) = 0.458;$$

$$\text{Gain}(D^1, \text{触感}) = 0.458.$$

“根蒂”、“脐部”、“触感” 3 个属性均取得了最大的信息增益, 可任选其中之一作为划分属性. 类似的, 对每个分支结点进行上述操作, 最终得到的决策树如图 4.4 所示.

□ 决策树学习算法将对每个分支结点做进一步划分，最终得到的决策树如图：



信息增益的不足

- 偏向选择取值数量更多的属性。
- 改进办法：
- C4.5 提出信息增益率：通过“分裂信息”惩罚取值过多的属性，平衡属性基数对选择结果的影响。
- 分裂信息：衡量“属性 A 分裂数据集时的‘分散程度’”，取值越多的属性，分裂信息越大，以此作为惩罚项。

分裂信息 (Split Information)

- **分裂信息**：衡量“属性 A 分裂数据集时的‘分散程度’”，取值越多的属性，分裂信息越大，以此作为惩罚项。

$$\text{SplitInfo}(D, A) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \cdot \log_2 \left(\frac{|D_j|}{|D|} \right)$$

其中 $|D_j|$ 是第 j 类样本数， $|D|$ 是总样本数。

举例：若属性 A 有 100 个取值（如身份证号），分裂后每个子集仅 1 个样本，则 $|D_j|/|D| = 1/100$ ， $\text{SplitInfo}(D, A) \approx 6.64$ ；

若属性 A 仅 2 个取值（如性别），分裂后子集占比为 0.5 和 0.5，则 $\text{SplitInfo}(D, A) = 1$ 。

信息增益率

- 信息增益率是“信息增益”与“分裂信息”的比值，公式为

$$\text{GainRatio}(D, A) = \frac{\text{Gain}(D, A)}{\text{SplitInfo}(D, A)}$$

- 逻辑：当属性 A 取值过多时，SplitInfo(D, A) 增大，即使 Gain(D, A) 较高，比值（增益率）也会被拉低，从而避免选择无意义的高基数属性。

信息增益率计算示例

$$\text{GainRatio}(D, A) = \frac{\text{Gain}(D, A)}{\text{SplitInfo}(D, A)}$$

$$\text{SplitInfo}(D, A) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \cdot \log_2 \left(\frac{|D_j|}{|D|} \right)$$

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

最终结果汇总

特征	信息增益 (Gain)
----	-------------

色泽	≈ 0.109
----	---------

根蒂	≈ 0.143
----	---------

敲声	≈ 0.141
----	---------

纹理	≈ 0.381
----	---------

脐部	≈ 0.289
----	---------

触感	≈ 0.006
----	---------

结论

- 信息增益最高的特征是纹理 (≈ 0.381) ；
- 信息增益率最高的特征也是纹理 (≈ 0.272) ，说明 “纹理” 是区分好瓜 / 坏瓜的最有效特征。

结论信息增益最高的特征是纹理 ≈0.381, 信息增益率最高的特征也是纹理≈ 0.272, 说明 “纹理” 是区分好瓜 / 坏瓜的最有效特征。

C4.5 算法的完整流程

- (1) **初始化**：将所有训练样本作为根节点的初始数据集 D ；
- (2) **终止条件判断**：若 D 满足以下任一条件，停止分裂，将当前节点设为叶节点（类别为 D 中占比最高的类别）：
 - D 中所有样本属于同一类别；
 - 无剩余特征可用于分裂（或所有特征的增益率均为 0）；
 - D 中样本数量过少（低于阈值）；
- (3) **属性选择**：对所有可用属性，计算其信息增益率（连续属性需先离散化，缺失值需加权处理），选择增益率最高的属性 A ；
- (4) **分裂节点**：根据属性 A 的取值（离散属性按取值，连续属性按最优分割点），将 D 分裂为多个子节点，每个子节点对应一个子集；
- (5) **递归分裂**：对每个子节点，重复步骤 2-4，直到所有节点满足终止条件；
- (6) **后剪枝**：用验证集对完整树进行后剪枝，删除冗余节点。

模型的评价

- 模型选择是在某个模型类中选择最好的模型，而模型评价对这个最好的模型进行评价。模型评价阶段不做参数调整而是**客观地评价模型的预测能力**。
- 分类问题相关指标
 - 混淆矩阵：主要用于比较分类结果和实例的真实信息。矩阵中的每一行代表实例的预测类别，每一列代表实例的真实类别。

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

模型的评价

■ 混淆矩阵:

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

真阳性 (True Positive, TP) : 样本的真实类别是正例, 并且模型预测的结果也是正例

真阴性 (True Negative, TN) : 样本的真实类别是负例, 并且模型将其预测成为负例

假阳性 (False Positive, FP) : 样本的真实类别是负例, 但是模型将其预测成为正例

假阴性 (False Negative, FN) : 样本的真实类别是正例, 但是模型将其预测成为负例

模型的评价

- **准确率 (Accuracy) :** 准确率是最常用的分类性能指标, 即正确预测的正反例数 / 总数。

$$Accuracy = \frac{(TP + TN)}{(TP + FN + FP + TN)}$$

- **精确率 (Precision) :** 针对预测正确的正样本而不是所有预测正确的样本。表现为预测出是正的里面有多少真正是正的。可理解为**查准率**。即正确预测的正例数 / 预测正例总数。

$$Precision = \frac{TP}{(TP + FP)}$$

模型的评价

- 召回率 (Recall) 召回率表现出在实际正样本中，分类器能预测出多少。与真正率相等，可理解为查全率。即正确预测的正例数/实际正例总数。

$$Recall = \frac{TP}{(TP + FN)}$$

- F1 score: 精确率和召回率的调和值，更接近于两个数较小的那个，所以精确率和召回率接近时，F值最大。很多推荐系统的评测指标就是用F值的。

$$F_1 = \frac{(1 + \beta^2) \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

模型的评价

- 比 F_1 更一般的形式 F_β :

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

$\beta = 1$: 标准 F_1

$\beta > 1$: 偏重查全率 (逃犯信息检索)

$\beta < 1$: 偏重查准率 (商品推荐系统)

- 回归问题相关指标

- 平均绝对值误差 (MAE) : 表示预测值和观测值之间绝对误差的平均值。

$$MAE(X, h) = \frac{1}{m} \sum_{i=1}^m |h(x_i) - y_i|$$

- 均方误差 (MSE) : 表示参数估计值与参数真值之差平方的期望值。

$$MSE(X, h) = \frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2$$

- 均方根误差 (RMSE) : 表示预测值和观测值之间差异的样本标准差。
均方根误差为了说明样本的离散程度。做非线性拟合时, RMSE 越小越好。

$$RMSE(X, h) = \sqrt{\frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2}$$